

Avaliação do Modelo BTHOWeN em Datasets MultiClasses

Breno Tostes Eduardo Naslauský Felipe Barrocas
Giordano Souza Maria Bianca Irace Miguel Sousa
Rafael Paladini

16 de maio de 2025

Resumo

Este trabalho avalia o modelo BTHOWeN (Bleached Thermometer-encoded Hashed-input Optimized Weightless Neural Network) em diversos datasets multiclases. Comparamos a performance do BTHOWeN com o modelo BloomWiSARD, analisando o impacto dos hiperparâmetros na acurácia final. Utilizamos uma abordagem gulosa para otimização, variando sequencialmente os parâmetros de tamanho de endereço, número de discriminadores, funções hash, filtros Bloom e fator de bleaching. Os resultados demonstram as vantagens do BTHOWeN em termos de acurácia e eficiência para diversos conjuntos de dados de classificação.

1 Introdução

BTHOWeN vem de Bleached Thermometer-encoded Hashed-input Optimized Weightless Neural Network, e como o nome indica, é uma arquitetura de rede neural sem peso que se diferencia do uso do modelo WiSARD (Wilkes, Stonham and Aleksander Recognition Device) [1] por:

- Incorporar counting Bloom filters para reduzir o tamanho do modelo e permitir bleaching [4].
- Usar função hash que não requer operações aritméticas [5].
- Fazer encoding com termômetro não-linear de distribuição normal para melhorar a acurácia do modelo [5, 4].

2 Proposta

2.1 Metodologia

Neste trabalho, iremos replicar o BTHOWeN utilizando o BloomWisard como cerne, com os diferentes datasets multiclases inclusos no artigo original. A proporção entre a massa de treinamento e a massa de teste foi mantida idêntica às

respectivas proporções originais, porém os hiperparâmetros foram configurados para verificar o impacto de cada um deles na acurácia final.

Os hiperparâmetros configuráveis são:

- Tamanho do endereço (ou tamanho da tupla).
- Número de discriminadores.
- Número de funções hash.
- Número de filtros de bloom.
- Fator do bleaching.

Os experimentos são feitos alterando um hiperparâmetro de cada vez, de maneira gulosa. Ao atingir um valor máximo variando apenas um hiperparâmetro, este tem seu valor mantido pelo resto do experimento, e o próximo hiperparâmetro passa a ser o variável. Ao realizar este procedimento com todos os hiperparâmetros, identificamos o melhor resultado.

Tomamos o maior valor de acurácia de todos os experimentos e sua configuração de hiperparâmetros como melhor valor obtido e o comparamos com a acurácia obtida no artigo original.

2.2 Hiperparâmetros

2.2.1 Tamanho do Endereço (Tamanho da Tupla)

O tamanho do endereço, também conhecido como tamanho da tupla, é um parâmetro da WiSARD que determina a quantidade de bits de entrada que são agrupados para formar um endereço para cada RAM no discriminador [1]. No contexto do BTHOWeN, o tamanho do endereço define quantos bits são agrupados para endereçar cada filtro de Bloom, afeta o número total de filtros necessários (número total de entradas dividido pelo tamanho da tupla) e determina o espaço de endereçamento para cada filtro ($2^{\text{tamanho da tupla}}$ possíveis endereços em WiSARD tradicional) [3].

Tuplas menores resultam em mais filtros e melhor generalização, enquanto tuplas maiores reduzem o número de filtros, mas podem afetar a capacidade de generalização [4]. Nos experimentos, este parâmetro varia conforme o dataset, desde valores pequenos (2 para Iris) até valores maiores (28 para MNIST).

2.2.2 Número de Discriminadores (OWeN)

O número de discriminadores no BTHOWeN está relacionado à estrutura de entrada do modelo, em que discriminador é responsável por processar uma parte específica do vetor de entrada, segmentando os dados de entrada em subconjuntos de bits [1, 4].

O número de discriminadores para cada classe é determinado pela divisão da dimensão total da entrada pelo número de bits por filtro [4]. Por exemplo,

em um modelo para MNIST com entrada de 784 pixels (28x28) e 28 bits por filtro, teríamos 28 discriminadores por classe.

O valor do parâmetro OWeN representa o número de bits de entrada que cada discriminador recebe [4, 5]. Quanto maior este valor, mais granular é a segmentação dos dados, o que pode melhorar a capacidade de distinção, mas aumenta a complexidade computacional.

2.2.3 Número de Funções Hash (FH)

As funções hash são utilizadas nos filtros de Bloom para mapear os dados de entrada em posições de memória [4]. O parâmetro FH determina quantas diferentes funções hash são utilizadas em cada filtro de Bloom.

BTHOWeN implementa a família de funções hash H3, conforme descrita por Carter e Wegman, que não requer operações aritméticas complexas, sendo ideal para implementações em hardware [5].

O número de funções hash tem uma relação complexa com a taxa de falsos positivos [4]:

- Valores típicos variam de 1 a 4, dependendo do dataset
- Um maior número de funções hash pode aumentar o poder discriminativo do modelo, mas também eleva o custo computacional
- Os melhores resultados obtidos nos experimentos utilizaram de 1 a 4 funções hash, dependendo da complexidade da tarefa

2.2.4 Número de Filtros de Bloom (FE - Filter Entries)

O parâmetro FE define o número de entradas em cada filtro de Bloom, ou seja, o tamanho do vetor utilizado para armazenar os padrões aprendidos [4]. Este tamanho é uma potência de 2 (por exemplo, 128, 256, 512, 1024, 2048, etc.).

Aumentar o tamanho do filtro reduz a probabilidade de colisões e, consequentemente, a taxa de falsos positivos, mas também aumenta a memória necessária [4, 5]. A escolha deste parâmetro afeta diretamente o equilíbrio entre precisão e eficiência de memória do modelo.

Em hardware, este parâmetro se traduz na quantidade de memória alocada para cada filtro, influenciando o consumo de energia [5].

2.2.5 Fator de Bleaching (b)

O fator de bleaching é um hiperparâmetro introduzido pela arquitetura BTHOWeN, que não existia em outras redes neurais sem peso anteriores [4]. Em implementações tradicionais de filtros de Bloom, cada posição de memória armazena apenas um bit (0 ou 1), indicando se um padrão foi visto ou não [4, 2].

Na BTHOWeN, cada posição armazena um contador, permitindo registrar quantas vezes um determinado padrão foi encontrado durante o treinamento [4]. O fator de bleaching define o limiar mínimo de ocorrências para que um padrão seja considerado válido durante a inferência.

Funcionamento [4, 5]:

- Durante o treinamento, os contadores são incrementados cada vez que um padrão é encontrado
- Na inferência, um padrão é considerado presente apenas se seu contador for $\geq b$
- Aumentar o valor de b pode melhorar a precisão ao reduzir falsos positivos
- Valores comuns de b variam de 1 a 10, sendo o valor ótimo determinado durante o treinamento

A técnica de bleaching permite ao modelo distinguir padrões frequentes e relevantes em detrimento de ocorrências aleatórias e ruidosas, melhorando a capacidade de generalização do modelo [4].

2.3 Datasets

2.3.1 MNIST

O dataset **MNIST** (Modified National Institute of Standards and Technology) é uma coleção de dígitos manuscritos. Ele inclui **60k imagens de treinamento** e **10k imagens de teste**. Todas as imagens estão em escala de cinza e possuem tamanho de **28×28 pixels**.

2.3.2 Ecoli

O dataset **Ecoli** é usado para prever onde proteínas celulares se localizam com base em suas sequências de aminoácidos. Ele contém **336 proteínas**, cada uma descrita por **sete atributos numéricos** derivados da sequência. As proteínas são classificadas em **oito possíveis locais celulares**.

2.3.3 Iris

O dataset **Iris** contém **150 observações** de flores de íris, cada uma descrita por:

- Comprimento da sépala.
- Largura da sépala.
- Comprimento da pétala.
- Largura da pétala.

A classificação é feita em uma de **três espécies**: **Iris Setosa**, **Versicolor** ou **Virginica**.

2.3.4 Glass

O dataset **Glass** contém **214 instâncias** de fragmentos de vidro, cada uma descrita por **10 atributos**. Com ele, conseguimos prever o tipo de vidro com base em sua composição química e índice de refração.

2.3.5 Letter

O dataset **Letter** contém letras manuscritas. As imagens dos caracteres foram baseadas em **20 fontes diferentes**, e cada letra dentro dessas fontes foi distorcida aleatoriamente para produzir:

- **20k entradas**, onde:
 - **16k** foram usadas para treinamento.
 - **4k** para teste.

2.3.6 Wine

O dataset **Wine** reúne **178 amostras** de vinho de três cultivares de uvas da região de Piemonte, Itália. Cada amostra é descrita por **13 atributos químicos contínuos** – como teor de álcool, magnésio e intensidade de cor. O objetivo é identificar a cultivar correta entre as **três classes** disponíveis.

2.3.7 Segment

O dataset **Image Segmentation** (Segment) contém **2.310 segmentos** de imagens externas, distribuídos igualmente entre **sete classes** de região: tijolo, céu, folhagem, cimento, janela, caminho e grama. Cada segmento é representado por **19 atributos numéricos** que descrevem características de cor e textura. A tarefa é prever a classe da região na qual o segmento se enquadra.

2.3.8 Shuttle

O dataset **Statlog Shuttle** possui cerca de **58.000 registros** de telemetria do sistema de controle do ônibus espacial. Cada registro é descrito por **nove atributos numéricos** derivados de sensores a bordo e está rotulado em um de **sete possíveis estados operacionais**. O conjunto é fortemente desbalanceado, com predominância da classe 1.

2.3.9 Vehicle

O dataset **Vehicle Silhouettes** contém **846 silhuetas** de veículos, cada uma descrita por **18 medidas geométricas** extraídas da imagem, como área, compactidade e momentos. Os veículos devem ser classificados em uma de **quatro categorias**: ônibus, Opel, Saab ou van.

2.3.10 Vowel

O dataset **Vowel Recognition** inclui **990 amostras** de fala gravadas por 15 locutores. Cada amostra é caracterizada por **10 atributos acústicos contínuos** (coeficientes derivados do espectro) e deve ser classificada em uma de **11 vogais** do inglês, como /a/, /e/ ou /i/.

3 Resultados

3.1 Resultados por dataset

3.1.1 Tabelas

Tabela 1: Parâmetros e métricas do dataset Iris

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Iris	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	960	2.0	
Iris	BTHOWeN Base Estudo	3	2	128	1	980	12.0	
Iris	BTHOWeN Variação 1	4	2	128	1	920	16.0	
Iris	BTHOWeN Variação 2	3	2	256	1	980	14.0	
Iris	BTHOWeN Variação 3	3	2	128	2	980	8.0	
Iris	BTHOWeN Variação 4	4	2	128	2	860	4.0	
Iris	BTHOWeN Variação 5	3	2	256	2	980	0.0	
Iris	BTHOWeN Variação 6	4	2	256	2	900	12.0	

Tabela 2: Parâmetros e métricas do dataset Ecoli

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Ecoli	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	799	N/A	
Ecoli	BTHOWeN Base Estudo	10	128	2	10	786	8.9	
Ecoli	BTHOWeN Variação 1	4	128	2	11	821	10.7	
Ecoli	BTHOWeN Variação 2	3	256	2	10	813	19.6	
Ecoli	BTHOWeN Variação 3	3	128	3	10	786	15.2	
Ecoli	BTHOWeN Variação 4	4	128	3	11	839	17.9	
Ecoli	BTHOWeN Variação 5	3	256	3	10	848	10.7	
Ecoli	BTHOWeN Variação 6	4	256	4	10	830	13.4	

Tabela 3: Parâmetros e métricas do dataset Glass

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Glass	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	726	N/A	
Glass	BTHOWeN Base Estudo	3	128	3	9	577	39.4	
Glass	BTHOWeN Variação 1	4	128	3	10	563	38.0	

Glass	BTHOWeN Variação 2	3	256	3	9	493	33.8	
Glass	BTHOWeN Variação 3	3	128	4	9	549	19.7	
Glass	BTHOWeN Variação 4	4	128	4	10	592	40.8	
Glass	BTHOWeN Variação 5	3	256	4	9	676	29.6	
Glass	BTHOWeN Variação 6	4	256	4	10	676	28.2	

Tabela 4: Parâmetros e métricas do dataset Letter

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Letter	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	848	N/A	
Letter	BTHOWeN Base Estudo	3	128	3	9	734	18.6	
Letter	BTHOWeN Variação 1	4	128	3	10	736	17.4	
Letter	BTHOWeN Variação 2	3	256	3	9	789	15.2	
Letter	BTHOWeN Variação 3	3	128	4	9	707	19.2	
Letter	BTHOWeN Variação 4	4	128	4	10	719	18.7	
Letter	BTHOWeN Variação 5	3	256	4	9	775	15.6	
Letter	BTHOWeN Variação 6	4	256	5	12	811	11.3	
Letter	BTHOWeN Variação 7	11	256	5	18	840	7.6	
Letter	BTHOWeN Variação 8	15	256	5	35	884	3.9	

Tabela 5: Parâmetros e métricas do dataset Wine

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Wine	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	926	N/A	
Wine	Referência BTHOWeN	9	13	128	3	983	N/A	
Wine	BTHOWeN Base Estudo	9	13	128	3	983	N/A	
Wine	BTHOWeN Variação 1.1	10	13	256	4	1.000	1.7	
Wine	BTHOWeN Variação 1.2	10	13	256	4	949	3.39	
Wine	BTHOWeN Variação 2	11	9	256	4	983	1.69	
Wine	BTHOWeN Variação 3	11	13	256	2	966	3.38	
Wine	BTHOWeN Variação 4	9	9	256	4	966	1.69	
Wine	BTHOWeN Variação 5	10	17	256	4	966	11.8	
Wine	BTHOWeN Variação 6	11	15	256	2	966	N/A	
Wine	BTHOWeN Variação 7	7	9	256	4	932	5.08	

Tabela 6: Parâmetros e métricas do dataset Segment

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Segment	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	N/A	N/A	
Segment	Referência BTHOWeN	8	12	512	4	880	N/A	
Segment	BTHOWeN Base Estudo	9	27	1024	2	925	N/A	

Segment	BTHOWeN Variação 1	10	16	256	4	938	9.35	
Segment	BTHOWeN Variação 2	8	20	512	3	924	9.24	
Segment	BTHOWeN Variação 3.1	10	18	1024	3	942	8.57	
Segment	BTHOWeN Variação 3.2	10	18	1024	3	944	6.49	
Segment	BTHOWeN Variação 4	10	20	512	2	944	8.96	
Segment	BTHOWeN Variação 5	16	16	256	3	941	10.8	
Segment	BTHOWeN Variação 6	10	14	512	4	939	8.10	
Segment	BTHOWeN Variação 7	9	20	1024	2	937	23.7	
Segment	BTHOWeN Variação 8	15	15	256	4	936	9.8	
Segment	BTHOWeN Variação 9	9	32	2048	4	936	34.9	

Tabela 7: Parâmetros e métricas do dataset Shuttle

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)
Shuttle	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	868	N/A
Shuttle	Referência BTHOWeN README	9	27	1024	2	868	N/A
Shuttle	BTHOWeN Base Estudo	9	27	1024	2	0	0
Shuttle	BTHOWeN Variação 1.1	11	29	1024	2	999	0.11
Shuttle	BTHOWeN Variação 1.2	11	29	1024	2	998	0.17
Shuttle	BTHOWeN Variação 2	11	25	1024	3	999	0.10
Shuttle	BTHOWeN Variação 3	8	27	1024	1	998	0.21
Shuttle	BTHOWeN Variação 4	9	23	512	3	998	0.21
Shuttle	BTHOWeN Variação 5	8	23	2048	1	998	0.70
Shuttle	BTHOWeN Variação 6	7	27	1024	2	989	2.55
Shuttle	BTHOWeN Variação 8	11	27	1024	2	976	4.99

Tabela 8: Parâmetros e métricas do dataset Vehicle

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)
Wine	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	926	N/A
Vehicle	Referência BTHOWeN README	16	16	256	3	662	N/A
Vehicle	BTHOWeN Base Estudo	16	16	256	3	N/A	N/A
Vehicle	BTHOWeN Variação 1	14	14	512	4	755	32.1
Vehicle	BTHOWeN Variação 11	15	12	256	2	755	20.2
Vehicle	BTHOWeN Variação 19	18	16	512	2	748	30.3
Vehicle	BTHOWeN Variação 9	18	18	512	3	737	25.5
Vehicle	BTHOWeN Variação 18	16	14	512	2	734	20.2
Vehicle	BTHOWeN Variação 10	15	16	512	3	726	32.8
Vehicle	BTHOWeN Variação 15	14	12	512	3	726	27.5

Tabela 9: Parâmetros e métricas do dataset Vowel

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	M
Vowel	Referência Bloom WiSARD	N/A	N/A	N/A	N/A	876	N/A	
Vowel	Referência BTHOWeN	15	15	256	4	876	N/A	
Vowel	BTHOWeN Base Estudo	15	15	256	4	0	0	
Vowel	BTHOWeN Variação 16	15	13	512	5	924	24.4	
Vowel	BTHOWeN Variação 8	16	11	256	3	918	21.8	
Vowel	BTHOWeN Variação 9	16	11	256	5	918	0	
Vowel	BTHOWeN Variação 19	17	11	512	5	918	23.0	
Vowel	BTHOWeN Variação 18	14	11	128	3	912	28.8	
Vowel	BTHOWeN Variação 17	16	13	512	5	909	0	
Vowel	BTHOWeN Variação 5	16	17	256	5	906	0	

Tabela 10: Parâmetros e métricas do dataset MNIST

Dataset	Config Type	b	OWeN	FE	FH	Acurácia	Empates (%)	Melhor
MNIST	ULEEN Base Estudo	6	49	8192	4	952	N/A	M
MNIST	Referência BTHOWeN	2	28	1024	2	934	N/A	M
MNIST	BTHOWeN Base Estudo	2	28	1024	2	929	1.61	
MNIST	BTHOWeN Variação 1	16	16	256	3	915	N/A	M
MNIST	BTHOWeN Variação 2	15	15	256	4	913	N/A	M
MNIST	BTHOWeN Variação 3	9	27	1024	2	933	N/A	M
MNIST	BTHOWeN Variação 4	4	16	512	2	918	2.1	
MNIST	BTHOWeN Variação 5	8	20	512	3	921	N/A	M
MNIST	BTHOWeN Variação 6	4	24	256	2	916	N/A	M
MNIST	BTHOWeN Variação 7	8	32	2048	4	943	0.36	

3.2 Resultados agregados

...

4 Conclusão

...

Referências

- [1] Aluizio S. Lima Filho, Gabriel P. Guarisa, Leopoldo A. D. Lusquino Filho, Luiz F. R. Oliveira, Felipe M. G. França, and Priscila M. V. Lima. wisardpkg - a library for wisard-based models. *arXiv preprint arXiv:2005.00887*, 2020.
- [2] Leopoldo A. D. Lusquino Filho, Luiz F. R. Oliveira, Aluizio Lima Filho, Gabriel P. Guarisa, Lucca M. Felix, Priscila M. V. Lima, and Felipe M. G.

- França. Extending the weightless wisard classifier for regression. *Neurocomputing*, 419:125–138, 2020.
- [3] Leandro Santiago. Redes sem peso wisard - soluções para memória eficiente, 2023. Apresentação sobre modelos WiSARD e otimizações de memória.
 - [4] Leandro Santiago, Leticia Verona, Fabio Rangel, Fabrício Firmino, Daniel S. Menasché, Wouter Caarls, Mauricio Breternitz Jr, Sandip Kundu, Priscila M. V. Lima, and Felipe M. G. França. Weightless neural networks as memory segmented bloom filters. *Neurocomputing*, 416:354–366, 2020.
 - [5] Zachary Susskind, Aman Arora, Igor D. S. Miranda, Luis A. Q. Villon, Rafael F. Katopodis, Leandro S. Araújo, Diego L. C. Dutra, Priscila M. V. Lima, Felipe M. G. França, Mauricio Breternitz Jr, and Lizy K. John. Weightless neural networks for efficient edge inference. In *PACT '22: International Conference on Parallel Architectures and Compilation Techniques*, New York, NY, USA, 2022. ACM.